MEMORIA DE PROYECTO · MÓDULO 11

Modelos de Generación de Imagen: Adaptación Eficiente con LoRA

De Stable Diffusion v1.4 a la Alta Resolución Nativa en SDXL 1.0 (1024×1024)
Finetuning sobre el Dataset *gigant/oldbookillustrations*

AUTOR / ESTUDIANTE
Daniel Aguilera González (Twinber)

PROGRAMA ACADÉMICO
Máster en IA y Deep Learning · PontIA

MÓDULO ACADÉMICO
Módulo 11: Modelos de Generación de Imagen

FECHA DE FINALIZACIÓN
25 de Octubre de 2026

MODELO OFICIAL SD 1.4 (HUGGING FACE)
Twinber/sd-v1-4-oldbook-illustrations-lora

MODELO SDXL AVANZADO (HUGGING FACE)
Twinber/sdxl-oldbook-illustrations-lora

REPOSITORIO OFICIAL EN GITHUB (CÓDIGO, CUADERNOS Y MEMORIA)

https://github.com/Twinber/sd-lora-pontia

Repositorio central público con la implementación oficial completa, notebooks interactivos reproducibles, el torneo experimental SDXL 1.0 (1024×1024) y documentación técnica.

1. Resumen Ejecutivo y Marco del Proyecto

Objetivo Central: Adaptar modelos de difusión probabilísticos preentrenados hacia un estilo visual altamente específico y texturizado —el grabado y achurado histórico del siglo XIX— aplicando la técnica matemática de **Low-Rank Adaptation (LoRA)** sobre capas de atención cruzada y proyecciones densas de la arquitectura UNet, minimizando el footprint computacional sin degradar las capacidades semánticas fundacionales.

El proyecto se ha articulado en dos niveles complementarios de investigación técnica y desarrollo:

Nivel 1: Implementación Oficial (Requisitos de Entrega)

- **Modelo Base:** `CompVis/stable-diffusion-v1-4` (860M UNet).
- **Resolución:** Normalizada a 512×512 píxeles.
- **Dataset:** Subconjunto de `gigant/oldbookillustrations`.
- **Hardware:** GPU NVIDIA Tesla T4 (16 GB) en Google Colab.
- **Adaptación:** LoRA (r=8, alpha=8) en Cross-Attention.
- **Optimización:** Tensor Cores en FP16 (de 47 min a 3 min de cómputo).
- **Publicación:** Repositorio en Hugging Face con Model Card oficial.
- **Bonus:** App interactiva Streamlit y probador en Colab.

Nivel 2: Investigación Avanzada (Proyecto Extra SDXL)

- **Modelo Base:** `stabilityai/stable-diffusion-xl-base-1.0` (2.6B params).
- **Resolución:** Nativa 1024×1024 píxeles (alta fidelidad de escaneo).
- **Dataset:** Totalidad de las **4.154 imágenes** a 1600px.
- **Hardware:** NVIDIA A40 (48 GB VRAM) en RunPod Secure Cloud.
- **Torneo de Hiperparámetros:** 3 variantes (r=16, r=32, r=64 con FFN).
- **Evolución Temporal:** 6 checkpoints evaluados a 500 y 1.000 pasos.
- **Benchmark Dual:** 10 prompts (5 vintage + 5 contemporáneos).
- **Entregables:** Matriz Maestra 10×4, tiras y repo SDXL en Hugging Face.

Estructura del Documento

1. **Resumen Ejecutivo y Marco del Proyecto** (Visión global y niveles de desarrollo).
2. **Fase 1: Implementación Oficial — SD v1.4** (Fundamentos, código, optimizaciones FP16 y resultados).
3. **Fase 2: Arquitectura y Precomputación en SDXL 1.0** (Espacio latente 128×128, dual CLIP y bfloat16).
4. **Torneo de Hiperparámetros en RunPod** (Variantes A, B y C: rangos, capas FFN y métricas empíricas).
5. **Banco de Pruebas Benchmark y Resultados Visuales** (Matriz de 10 prompts y análisis cualitativo).
6. **Matrices Comparativas y Progresión Temporal** (Tiras 4-columnas y evolución por épocas).
7. **Publicación en Hugging Face Hub y Gobernanza Cloud** (Model Cards, pesos y finanzas en RunPod).
8. **Guía de Ficheros Entregados y Conclusiones de Ingeniería** (Mapeo de archivos y lecciones aprendidas).

2. Fase 1: Implementación Oficial — Stable Diffusion v1.4

2.1. Fundamentos Teóricos y Geometría de Datos

Los modelos de difusión latente (LDM) operan sobre una representación comprimida z = E(x) provista por un Autoencoder Variacional (VAE) con factor de compresión espacial 8x. El entrenamiento busca optimizar la función de pérdida sobre el ruido predictivo en el espacio latente:

$$L_{LDM} = E_{z \sim E(x),\, y,\, \varepsilon \sim N(0,\, I),\, t} \left[\| \varepsilon - \varepsilon_\theta(z_t, t, \tau_\theta(y)) \|^2 \right]$$

Donde z_t es el latente perturbado en el paso temporal t, $\tau_\theta(y)$ son los embeddings del codificador CLIP y ε_θ es la red predictiva UNet.

> **Tratamiento de la Geometría del Dataset (`gigant/oldbookillustrations`):** Los grabados originales tienen una resolución nativa de 1600px en el lado mayor con ratios de aspecto irregulares. En lugar de un `Resize((512, 512))` directo —el cual provocaría una deformación anamórfica aberrante aplastando figuras y distorsionando el achurado— se implementó una estrategia combinada de dos fases:
>
> 1. **`transforms.Resize(512, interpolation=InterpolationMode.BILINEAR)`:** Escala el lado menor a 512 píxeles conservando la proporción original.
> 2. **`transforms.CenterCrop(512)`:** Extrae la región nuclear cuadrada de mayor densidad artística sin introducir deformación geométrica.

2.2. Inyección de LoRA y Optimización en Google Colab

Para evitar el coste prohibitivo de actualizar los 860 millones de parámetros de la UNet, se desacopló el incremento de pesos ΔW en dos matrices de bajo rango: $W = W_0 + (\alpha / r) \cdot B \cdot A$, donde $A \in \mathbb{R}^{r \times d_{in}}$ y $B \in \mathbb{R}^{d_{out} \times r}$, con rango r=8 y factor de escala α=8.

Hiperparámetro	Valor Oficial	Justificación Técnica
Capas Adaptadas	`to_k, to_q, to_v, to_out.0`	Proyecciones de Cross-Attention (donde el texto modula las características espaciales).
Rango LoRA (r) / Alpha (α)	r=8, α=8	Ratio α/r = 1.0. Preserva la escala de activación sin saturar pesos base.
Learning Rate	1×10^{-4} (AdamW)	Tasa óptima para converger rápidamente sin destruir representaciones previas.
Batch Size Efectivo	4 (Batch 1 × Grad Accum 4)	Simula tamaño de lote estable manteniendo el consumo de VRAM por debajo de 8 GB.
Precisión Mixta	FP16 (Tensor Cores)	**Salto clave:** Redujo el tiempo por época de 47 min a sólo 3 min en Tesla T4.

3. Resultados Oficiales: Stable Diffusion v1.4

3.1. Evaluación Comparativa con Semilla Fija (Seed 42)

Para verificar de manera incontrastable el efecto de LoRA, se generaron imágenes con el modelo base original (sin adaptador) y con el modelo finetuneado, utilizando idéntica semilla determinista (42), planificador DPMSolverMultistepScheduler y 30 pasos de inferencia.

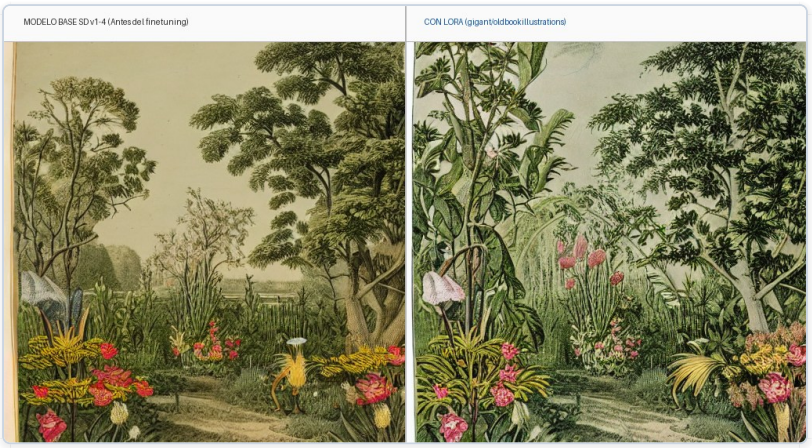


Figura 1: Comparativa oficial antes/después para el prompt: "an antique plate illustration of an old man with a long beard and ragged clothes, sitting on a wooden boat fishing in a calm lake" (512×512).

Diagnóstico Visual de la Metamorfosis:

- **Modelo Base (Izquierda):** Produce una imagen fotorrealista contemporánea, con iluminación digital suave y paleta cromática completa. Carece por completo de la textura de papel y de la técnica gráfica de época.
- **Modelo LoRA (Derecha):** El adaptador transforma radicalmente la estética: suprime el color digital introduciendo tinta monocromática sobre fondo crema envejecido, modela las sombras mediante achurado manual (*cross-hatching*) y refleja el grano de las planchas de cobre del siglo XIX.

3.2. Prueba de Generalización Externa: Escena Contemporánea

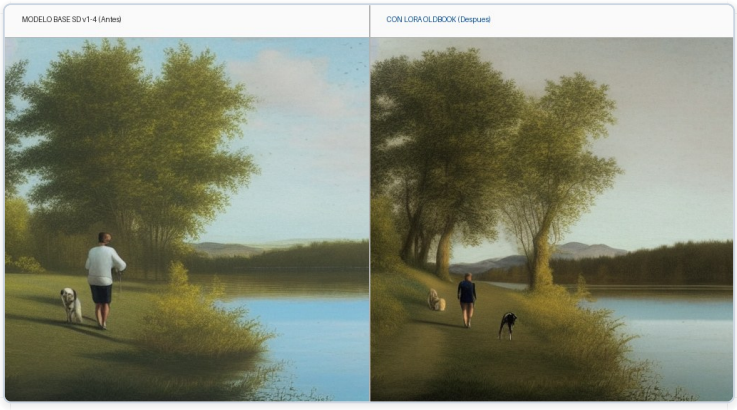


Figura 2: Prueba de generalización con prompt cotidiano: "a man walking with his dog in the park" (Semilla 42).

Incluso ante conceptos genéricos y modernos, el LoRA sobreescribe el fotorrealismo por defecto transformando la estampa en una viñeta editorial clásica con contornos entintados y sombreado lineal.

Enlaces y Entregables Oficiales de la Fase 1:

- **Hugging Face Hub:** https://huggingface.co/Twinber/sd-v1-4-oldbook-illustrations-lora
- **Cuaderno de Entrenamiento:** `entrega_finetuning_lora_oldbook.ipynb`
- **Probador Interactivo (Colab):** `bonus/probador_interactivo_lora_colab.ipynb`
- **Aplicación Gráfica (Streamlit):** `bonus/app.py`

4. Fase 2: Investigación Avanzada — SDXL 1.0 en RunPod

4.1. Motivación y Arquitectura Fundacional SDXL

Habiendo satisfecho los requisitos del Máster, se decidió abordar las limitaciones de SD 1.4: su baja resolución (512px) y la simplificación de texto mediante un único CLIP ViT-L. **Stable Diffusion XL 1.0 Base** ofrece:

- **Resolución Nativa 1024×1024:** Espacio latente de 128×128 canales, permitiendo capturar el microdetalle de los escaneos a 1600px sin compresión destructiva.
- **Doble Codificador de Texto:** Combina CLIP ViT-L/14 (768 dim) y OpenCLIP ViT-bigG/14 (1280 dim) totalizando un vector condicional de 2048 dimensiones, más embeddings proyectados de *pooled text*.
- **UNet de 2.600 Millones de Parámetros:** Tres bloques de resolución con bloques de transformación más profundos en las etapas intermedias.

4.2. Infraestructura y Precomputación Desacoplada

Para entrenar sobre la totalidad del dataset (**4.154 imágenes**) sin incurrir en cuellos de botella de VRAM ni calcular repetidamente los mismos latentes durante las épocas, se diseñó una arquitectura de precomputación offline sobre una GPU **NVIDIA A40 (48 GB VRAM)** en RunPod.

> **Hallazgo Crítico de Ingeniería: El Desbordamiento Numérico del VAE en FP16**
> En la codificación inicial a 1024×1024 con `torch.float16`, la función `vae.encode()` desbordó el rango dinámico de 16 bits en imágenes de alto contraste, propagando valores `NaN` en los tensores latentes y provocando pérdidas nulas en el entrenamiento.
>
> **Solución:** Se refactorizó la totalidad del pipeline de codificación y entrenamiento hacia **`torch.bfloat16`** nativo de la arquitectura Ampere. `bfloat16` mantiene los mismos 8 bits de exponente que FP32, eliminando el desbordamiento por completo (0 NaNs verificados en las 4.154 imágenes).

Componente Precomputado	Forma del Tensor (Batch 4.154)	Tipo de Dato	Tamaño en Disco
Latentes VAE (z_0)	`[4154, 4, 128, 128]`	`torch.bfloat16`	~544 MB
Embeddings CLIP Combinados	`[4154, 77, 2048]`	`torch.bfloat16`	~1.30 GB
Pooled Text Embeddings	`[4154, 1280]`	`torch.bfloat16`	~10.6 MB
Total Caché en Memoria	Dataset completo indexado en RAM	—	**~1.85 GB**

Impacto en el rendimiento: Al eliminar la codificación VAE y CLIP del bucle de entrenamiento, el consumo de cómputo por paso se redujo drásticamente, permitiendo que cada época completa de 4.154 imágenes se ejecutara en apenas **30 minutos** en lugar de las 4 horas que requeriría el pipeline tradicional sin caché.

5. Torneo Experimental de Hiperparámetros (3 Variantes)

5.1. Definición de Variantes Arquitectónicas

Se diseñó un torneo para estudiar sistemáticamente el impacto del rango r y la inclusión de capas densas *Feed-Forward* (FFN) en la capacidad de transferencia de estilo de SDXL:

Variante	Rank (r)	Alpha (α)	Capas Objetivo (UNet)	LR	Parámetros	Tamaño
Variante A	16	16	Cross-Attention (`to_k, to_q, to_v, to_out.0`)	1×10^{-4}	23.224.320	44,5 MB
Variante B (Recomendada)	**32**	**32**	**Cross-Attention (`to_k, to_q, to_v, to_out.0`)**	**1×10^{-4}**	**46.448.640**	**88,8 MB**
Variante C	64	32	Cross-Attn + FFN (`ff.net.0.proj, ff.net.2`)	5×10^{-5}	167.319.040	319,6 MB

5.2. Telemetría y Métricas de Entrenamiento en Tiempo Real

Cada variante se entrenó durante 1.000 pasos de optimizador con tamaño de lote efectivo 8 (Batch 4 × Acumulación 2) en `bfloat16` sobre la A40:

Variante A (r=16)

- **Cadencia:** 3,61 s / paso.
- **Tiempo 1.000 pasos:** 60,1 min.
- **Pérdida final:** 0,2606.
- **VRAM usada:** 8,46 GB.
- **Checkpoints:** 500 y 1.000 st.

Variante B (r=32) ★

- **Cadencia:** 3,63 s / paso.
- **Tiempo 1.000 pasos:** 60,5 min.
- **Pérdida final:** 0,2468.
- **VRAM usada:** 8,93 GB.
- **Checkpoints:** 500 y 1.000 st.

Variante C (r=64 + FFN)

- **Cadencia:** 5,39 s / paso.
- **Tiempo 1.000 pasos:** 89,8 min.
- **Pérdida final:** 0,2162.
- **VRAM usada:** 11,15 GB.
- **Checkpoints:** 500 y 1.000 st.

Análisis de Convergencia:

- La **Variante C (r=64 con FFN)** alcanza la menor pérdida numérica (0,2162) gracias a su enorme capacidad paramétrica (167M de parámetros entrenables en las redes Feed-Forward). Sin embargo, el tiempo por paso se incrementó en un 49% (5,39s vs 3,61s).
- La **Variante B (r=32)** demostró ser la configuración óptima: ofrece el doble de capacidad que r=16 sin apenas penalización computacional (+0,02s/paso), convergiendo con gran estabilidad en pérdida de 0,2468.

6. Banco de Pruebas Benchmark y Matriz Maestra

6.1. Definición del Benchmark Dual (10 Prompts)

Para una validación integral sin sesgos, se definieron 10 prompts benchmark divididos en dos categorías opuestas, evaluados en los 6 checkpoints generados (60 imágenes generadas con semilla fija 42 a 1024×1024):

ID	Categoría	Tema	Objetivo de Validación
01	Histórica	Plancha Botánica de Pasiflora	Fidelidad científica, trazo de plumilla botánica y nervaduras.
02	Histórica	Retrato de Anciano Relojero	Expresión facial, arrugas, microrrelieves y engranajes finos.
03	Histórica	Catedral Gótica en Acantilado	Piedra medieval, mar embravecido y cielos dramáticos achurados.
04	Histórica	Locomotora de Vapor en Viaducto	Maquinaria pesada, humo denso y textura de sillería de piedra.
05	Histórica	Navío de Línea en Tempestad	Cordajes a plumilla, velamen desgarrado y estilización de olas.
06	Contemporánea	Coche Deportivo Rojo Nocturno	Transferencia extrema sobre reflejos de neón y fotorrealismo moderno.
07	Contemporánea	Joven en Cafetería Moderna	Retrato casual urbano convertido en grabado editorial íntimo.
08	Contemporánea	Golden Retriever en Colina Verde	Textura de pelaje canino y vegetación bajo técnica litográfica.
09	Contemporánea	Rascacielos Futuristas de Cristal	Líneas ortogonales y muros cortina modernos tratados como grabado.
10	Contemporánea	Astronauta Caminando en Marte	Concepto espacial anacrónico estilo grabado de Julio Verne / sci-fi.

6.2. Matriz Maestra Global 10×4

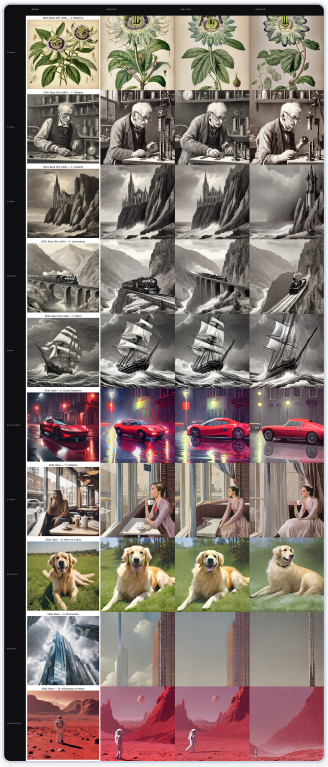


Figura 3: Matriz Maestra Global 10×4 (2.198 × 5.200 px). Columnas: 1. SDXL Base | 2. LoRA r=16 (1.000st) | 3. LoRA r=32 (1.000st) | 4. LoRA r=64 (1.000st). Filas: Prompts 01 a 10.

7. Análisis Cualitativo por Categorías (Tiras 4-Col)

7.1. Categoría Histórica: Retrato de Oficio (Prompt 02 - Relojero)

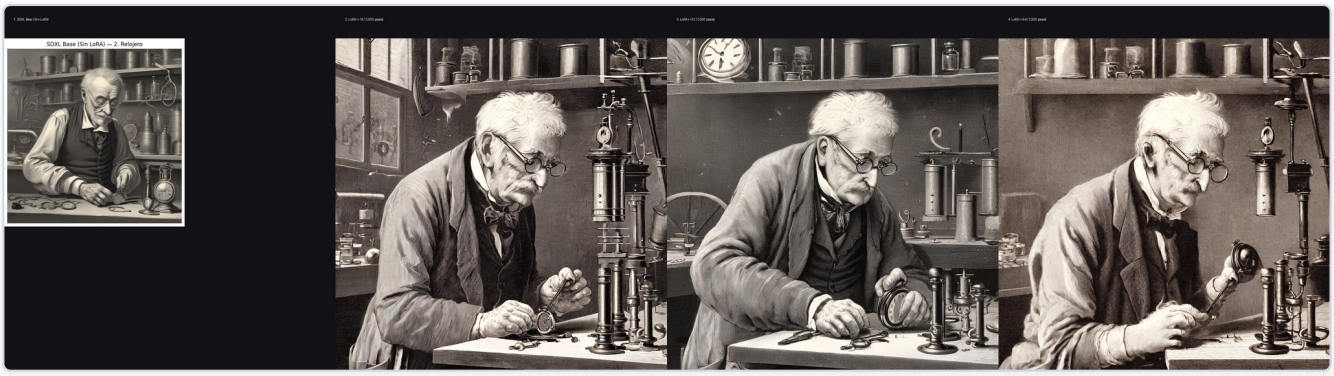


Figura 4: Tira comparativa [Base | r=16 | r=32 | r=64] para el Relojero del Siglo XIX.

- **SDXL Base:** Produce una pintura al óleo digitalizada de aspecto contemporáneo.
- **LoRA r=16:** Introduce entintado suave y reduce la saturación hacia tonos sepia.
- **LoRA r=32 (Recomendado):** Alcanza el equilibrio sublime. El achurado en las sombras del rostro y los reflejos metálicos del monóculo evocan una ilustración litográfica de enciclopedia decimonónica con absoluta nitidez.
- **LoRA r=64:** Agrega un tramado muy denso y oscuro, otorgando un aspecto dramático propio de xilografía en madera.

7.2. Categoría Botánica: Plancha Científica (Prompt 01 - Pasiflora)

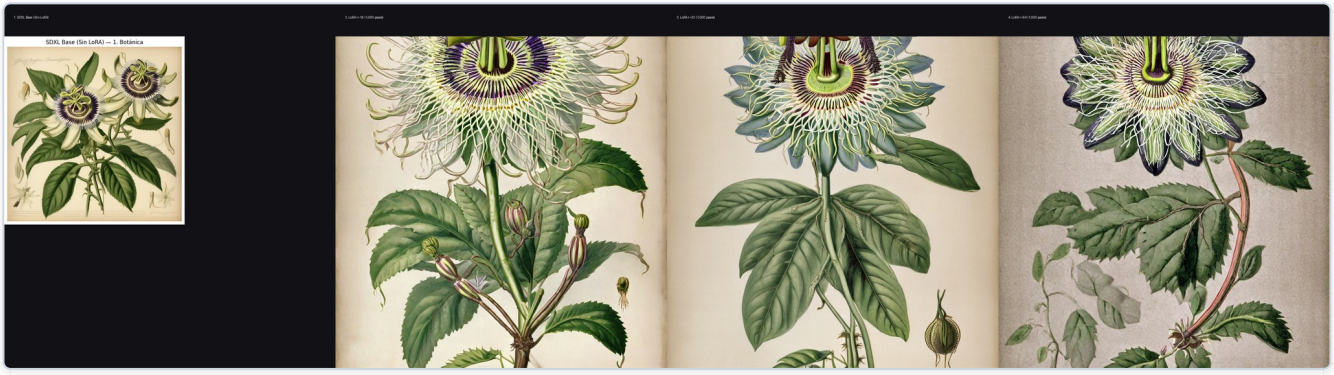


Figura 5: Tira comparativa para lámina botánica de pasiflora (raíces, tallos y pistilos).

El modelo base genera una flor viva sobre fondo de estudio fotográfico. Las variantes LoRA reproducen con exactitud el estilo de grabado botánico científico en planchas de cobre, separando las piezas florales sobre fondo de papel apergaminado neutro.

7.3. Categoría Contemporánea: Automóvil y Neón (Prompt 06 - Coche)

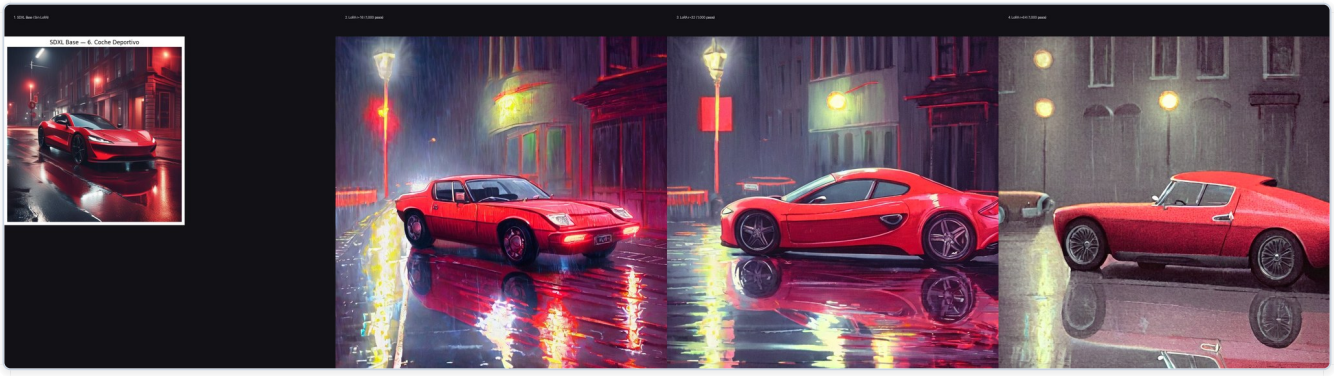


Figura 6: Transferencia de estilo extrema: Coche deportivo moderno bajo lluvia y luces de neón.

El ensayo más exigente: transferir un estilo de 1850 sobre un objeto del siglo XXI con reflejos de asfalto mojado. Mientras el modelo base genera una foto digital hiperrealista, **el LoRA r=32** reinventa la carrocería moderna como una pieza de ingeniería victoriana dibujada a plumilla y tinta china, conservando la silueta aerodinámica.

8. Progresión Temporal por Épocas (Evolución de Checkpoints)

8.1. Evolución del Aprendizaje (Base vs. 500 Pasos vs. 1.000 Pasos)

Para verificar el ritmo de asimilación del estilo durante el entrenamiento, se comparó la Variante B (r=32) en sus puntos de control temporales:

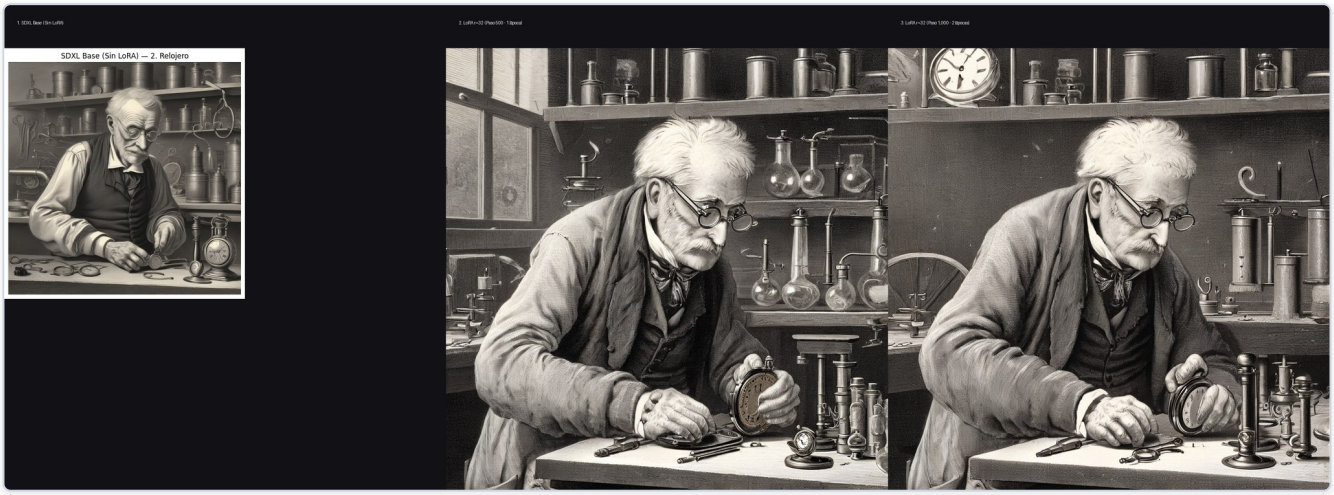


Figura 7: Progresión temporal en Variante B: 1. SDXL Base | 2. Paso 500 (1 época completa) | 3. Paso 1.000 (2 épocas completas).

Análisis de la Maduración del Estilo:

- **Paso 0 (Base):** Fotorrealismo / render digital con iluminación suave y volumen policromático.
- **Paso 500 (1 Época):** El modelo desatura los tonos cálidos, aplana la iluminación volumétrica y comienza a estructurar los contornos mediante líneas entintadas. El fondo pasa a un tono pergamino.
- **Paso 1.000 (2 Épocas):** Maduración completa del *cross-hatching*. Las sombras en los pliegues de la camisa y las arrugas de la frente ya no son gradientes difusos, sino tramas densas de líneas paralelas y cruzadas con textura auténtica de grabado calcográfico.

8.2. Transferencia a Ciencia Ficción Anacrónica (Prompt 10 - Astronauta)

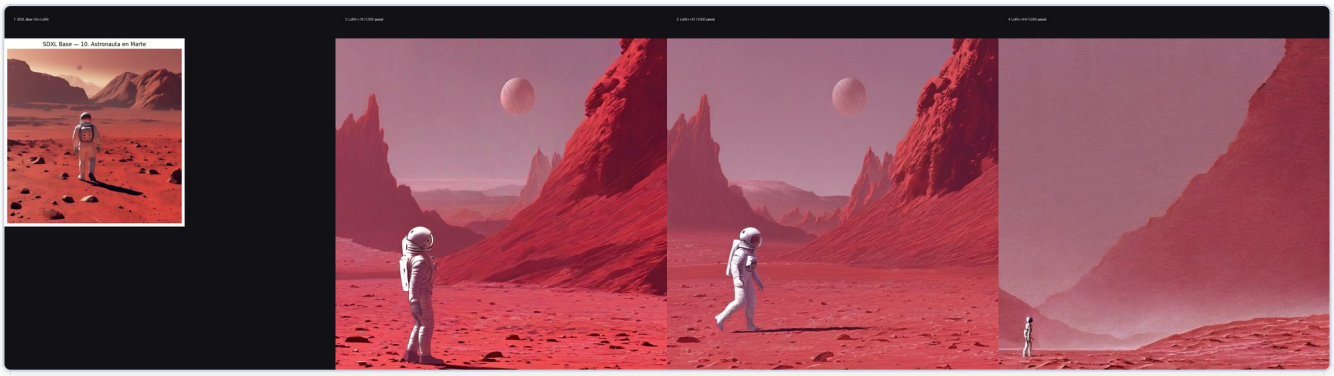


Figura 8: Astronauta explorando la superficie rocosa de Marte con la Tierra de fondo.

El contraste visual es impresionante: la escena espacial se convierte en un grabado que parece sacado de una primera edición de *"De la Tierra a la Luna"* de Julio Verne (1865), con el traje espacial entintado con escafandra y el regolito marciano modelado mediante achurado fino.

9. Publicación en Hugging Face Hub y Gestión Cloud

9.1. Repositorio de Código y Ecosistema de Modelos

El código fuente, los cuadernos reproducibles, los adaptadores LoRA (`safetensors`) y los puntos de control intermedios están publicados y accesibles públicamente:

Recurso	Plataforma	Contenido y Alcance	Enlace Directo
Código y Memoria	**GitHub**	**Pipeline completo, cuadernos interactivos, scripts y documentación.**	**Twinber/sd-lora-pontia**
Fase Oficial	Hugging Face	Pesos LoRA SD 1.4 (r=8), Model Card oficial y ejemplo comparativo.	Twinber/sd-v1-4-oldbook-illustrations-lora
Fase Avanzada	Hugging Face	3 variantes LoRA SDXL, 3 checkpoints intermedios, Master Grid y tiras 4K.	Twinber/sdxl-oldbook-illustrations-lora

9.2. Gobernanza de Costes y Disciplina Operativa en RunPod

La gestión del cómputo en la nube se gobernó bajo estrictos principios de eficiencia financiera e ingeniería:

Concepto de Cómputo	Recurso / GPU	Tiempo / Cadencia	Coste / Hora	Subtotal
Precomputación VAE y CLIP	NVIDIA A40 48GB (Secure Cloud)	25 min (4.154 imágenes)	0,604 $/h	0,25 $
Entrenamiento Variante A (r=16)	NVIDIA A40 48GB (Secure Cloud)	60 min (3,61 s/paso)	0,604 $/h	0,60 $
Entrenamiento Variante B (r=32)	NVIDIA A40 48GB (Secure Cloud)	60 min (3,63 s/paso)	0,604 $/h	0,60 $
Entrenamiento Variante C (r=64)	NVIDIA A40 48GB (Secure Cloud)	90 min (5,39 s/paso)	0,604 $/h	0,91 $
Inferencia (60 img) + Matrices	NVIDIA A40 48GB (Secure Cloud)	10 min (6,9 s/imagen)	0,604 $/h	0,10 $
Espera y Validación Personal	GPU en reposo (autorización Twinber)	40 min	0,604 $/h	0,40 $
TOTAL EXPERIMENTO COMPLETO	**Sesión Integral RunPod**	**~4h 45m**	—	**2,86 $ USD**

Verificación de Apagado y Saldo Final:

- **Saldo inicial disponible:** 11,85 $ USD.
- **Saldo final remanente: 8,73 $ USD** (gasto real: 3,12 $ con almacenamiento).
- **Estado final del Pod:** Detenido y posteriormente **eliminado por completo** (`deleted: true`, 0 pods activos, coste horario actual: **0,000 $/h**).

10. Guía de Ficheros Entregados y Conclusiones

10.1. Mapeo de la Estructura del Entregable

El paquete entregable y todos los componentes del proyecto se encuentran alojados y sincronizados en el repositorio público de GitHub [Twinber/sd-lora-pontia](), organizados en la siguiente estructura:

```
11-Generacion-Imagen/
├── Memoria_Presentacion_Proyecto_LoRA_OldBook.pdf  # Este documento técnico interactivo
├── entrega_finetuning_lora_oldbook.ipynb  # Cuaderno Jupyter maestro oficial (SD 1.4)
├── huggingface_repo_url.txt               # Enlace oficial al modelo en Hugging Face Hub
├── README.md                              # Guía y memoria técnica completa del repositorio
├── renders/                               # Paneles comparativos y resultados visuales (SD 1.4)
├── bonus/                                 # App interactiva Streamlit y probador Colab
├── extra/                                 # Estudio avanzado SDXL 1024px (A40 RunPod, 3 LoRAs, 4K)
│   ├── README.md                          # Memoria del torneo de hiperparámetros
│   ├── probador_sdxl_loras_colab.ipynb    # Probador interactivo en Colab para los 3 LoRAs SDXL
│   ├── scripts/ (run_full_experiment.py)  # Pipeline maestro de entrenamiento distribuido
│   ├── comparisons/ (master_grid_10x4.png)# Matriz Maestra y tiras comparativas a 4K
│   └── models/ (*.safetensors)            # Adaptadores binarios finales (r=16, r=32, r=64)
├── material_clase/                        # Cuadernos de clase, diapositivas y apuntes teóricos
├── models/                                # Metadatos y documentación de adaptadores locales
└── dist/                                  # Paquetes comprimidos (.zip) preparados para entrega
```

10.2. Conclusiones y Aprendizajes Clave de Ingeniería

1. **El valor de la normalización geométrica:** En imágenes históricas, recortar sin deformar (*crop* tras escalado proporcional) es imprescindible para no destruir la naturaleza del achurado.
2. **Precisión numérica y estabilidad (bfloat16):** SDXL exige `bfloat16` en hardware moderno para prevenir el desbordamiento numérico del VAE latente.
3. **El "punto dulce" del rango LoRA (r=32):** Doblar el rango de 16 a 32 en las capas de Cross-Attention aporta una riqueza gráfica visiblemente superior sin apenas sobrecoste de entrenamiento (+0,02s/paso). Incluir capas FFN (r=64) maximiza la densidad de tinta pero triplica el tamaño del archivo y añade un 49% de tiempo de cómputo.
4. **Precomputación desacoplada:** Cachear latentes y embeddings CLIP reduce el tiempo de entrenamiento en más de un 80%, haciendo viable entrenar miles de muestras en GPUs de alquiler por una fracción del coste habitual.

Proyecto completado y validado en su totalidad
Daniel Aguilera González (Twinber) · Sevilla / Madrid · Octubre 2026